课程实验二:实践 MapReduce 分布式数据处理

一、实验描述

本实验使用 IDEA 构建大数据工程,通过 Java 语言编写 WordCount 程序并通过集群运行,完成单词计数任务。首先,在本地进行 IDEA 的安装,接着使用 IDEA 构建大数据工程并编写 Wordcount 程序,最后将程序打包在先前实验构建的集群上运行程序。

二、实验目的

- 1. 了解 IDEA 构建大数据工程的过程;
- 2. 熟悉使用 Java 语言编写大数据程序;
- 3. 了解 MapReduce 的工作原理;
- 4. 掌握在集群上运行程序的方法。

三、实验环境

- 1. 系统版本: Centos 7.5;
- 2. Hadoop 版本: Apache Hadoop 2.7.7;
- 3. JDK 版本: 1.8.*;
- 4. IDEA 版本: IDEA2021.3。

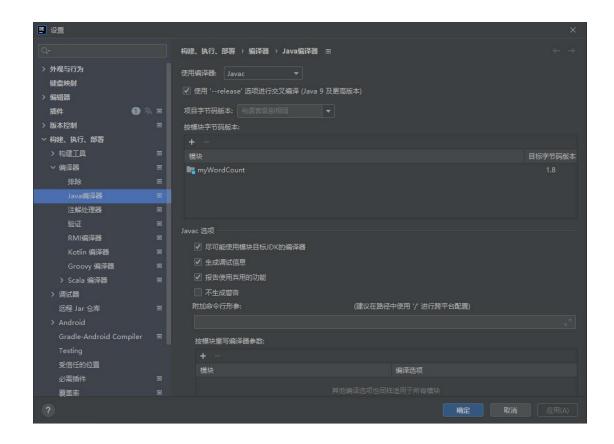
四、实验步骤

4.1 IDEA 构建大数据工程

步骤 1: 创建项目, 打开 IDEA, 创建工程

步骤 2: 依赖设置

步骤 3: 设置语言环境



步骤 4: 设置 java Compiler 环境

- 1)点击菜单栏中的 file,选择 Setting
- 2)依次选择 Build, Execution—->Compiler—->Java Compiler, 设置 Project bytecode version 为 1.8, 设置图中的 Target bytecode version 为 1.8, 然后依次点击 Apply 和 OK;

4.2 WordCount 程序编写

- 1) 依次打开 src—>main—>java, 在 java 上点击右键, 创建 Java Class;
- 2) 输入类名 WordCount,点击 ok
- 3)在类 WordCount 中添加 TokenizerMapper 类,并在该类中实现 map 函数; map 函数负责统计输入文件中单词的数量
- 4) 在类 WordCount 中添加 IntSumReducer 类,并在该类中实现 reduce 函数; reduce 函数合并之前 map 函数统计的结果,并输出最终结果;
 - 5) 在类 WordCount 中添加 main 方法;
 - 6) 创建 Configuration 对象,运行 MapReduce 程序前都要初始化。

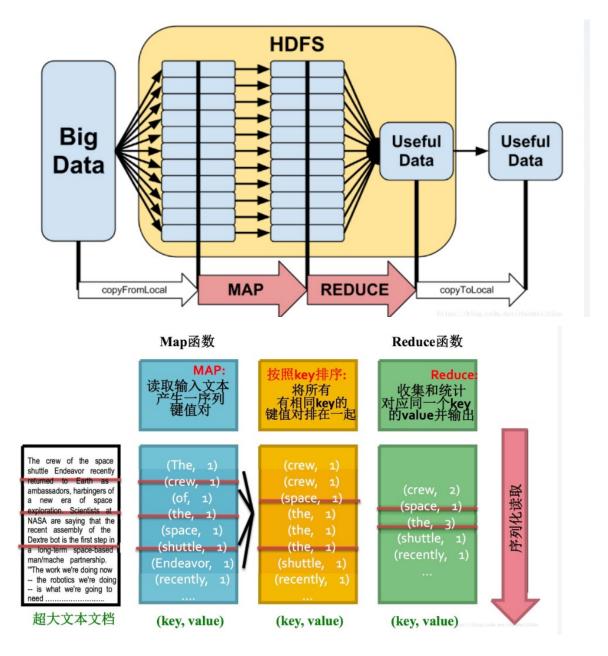
Configuration, 该类主要是读取 MapReduce 系统配置信息;

- 7) 限定输出参数必须为 2 个
- 8) 创建 Job 对象,第一行构建一个 job,构建时候有两个参数,一个是conf,一个是这个 job 的名称。
- 9)定义输出的 key/value 的类型,也就是最终存储在 HDFS 上结果文件的 key/value 的类型。
- 10) 构建输入的数据文件和输出的数据文件,如果 job 运行成功了,程序就会正常退出。

```
// 2019211279-rcx
import org.apache.hadoop.conf.Configuration;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;;
import org.apache.hadoop.mapreduce.Job;
import org.apache.hadoop.mapreduce.Mapper;
import org.apache.hadoop.mapreduce.Reducer;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
import org.apache.hadoop.util.GenericOptionsParser;
import java.io.IOException;
import java.util.StringTokenizer;
public class WordCount {
   //该类中实现 map 函数
    public static class TokenizerMapper extends Mapper<Object,</pre>
Text,Text, IntWritable> {
       private final static IntWritable one = new IntWritable(1);
       private Text word = new Text();
       //map 函数负责统计输入文件中单词的数量
       public void map(Object key, Text value, Context context) throws
IOException, InterruptedException{
           StringTokenizer itr = new
StringTokenizer(value.toString());
           while (itr.hasMoreTokens()){
               word.set(itr.nextToken());
               context.write(word,one);
```

```
//该类中实现 reduce 函数
   public static class IntSumReducer extends
Reducer<Text,IntWritable,Text,IntWritable>{
       private IntWritable result = new IntWritable();
       //reduce 函数合并之前 map 函数统计的结果
       public void reduce(Text key, Iterable<IntWritable>
values,Context context) throws IOException,InterruptedException{
          int sum=0;
          for(IntWritable val :values){
                  sum+=val.get();
          result.set(sum);
          context.write(key,result);
   public static void main(String[] args) throws Exception{
       //创建 Configuration 对象,运行 MapReduce 程序前都要初始化
Configuration,该类主要是读取 MapReduce 系统配置信息
       Configuration conf = new Configuration();
       //限定输出参数必须为 2 个
       String[] otherArgs = new GenericOptionsParser(conf,
args).getRemainingArgs();
       //运行 WordCount 程序时候一定是两个参数,如果不是就会输出错误提示并
       if(otherArgs.length!=2){
          System.err.println("Usage:wordcount <in> <out>");
          System.exit(2);
       //创建 Job 对象
       Job job =new Job(conf, "word count");
       //装载编写好的计算程序
       job.setJarByClass(WordCount.class);
       //载 Map 函数和 Reduce 函数实现类
       job.setMapperClass(TokenizerMapper.class);
       job.setCombinerClass(IntSumReducer.class);
       job.setReducerClass(IntSumReducer.class);
       //定义输出的 key/value 的类型
       job.setOutputKeyClass(Text.class);
       job.setOutputValueClass(IntWritable.class);
       //构建输入的数据文件
       FileInputFormat.addInputPath(job,new Path(otherArgs[0]));
       //构建输出的数据文件
```

```
FileOutputFormat.setOutputPath(job,new Path(otherArgs[1]));
//如果 job 运行成功了,程序就会正常退出
System.exit(job.waitForCompletion(true)? 0:1);
}
}
```



4.3 程序打包与运行

步骤 1: 打开 File->Project Structure:

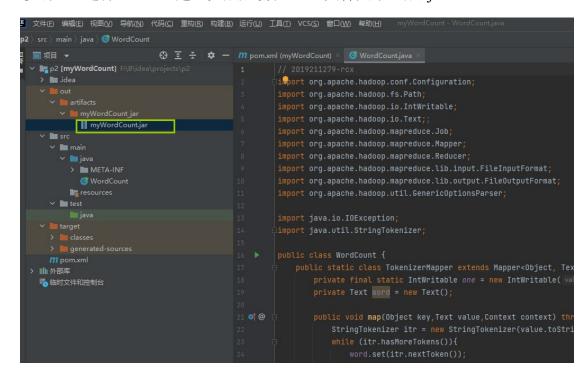
步骤 2: Project Settings 栏下的 Artifacts, 点击"+",选择 JAR->From

modules with dependencies...:

步骤 3: 填写主类名称:

步骤 4: 选择 Build->Artifacts:

步骤 5: 选择 Build: 建立完成后会在 out 文件夹下生成 jar 包:

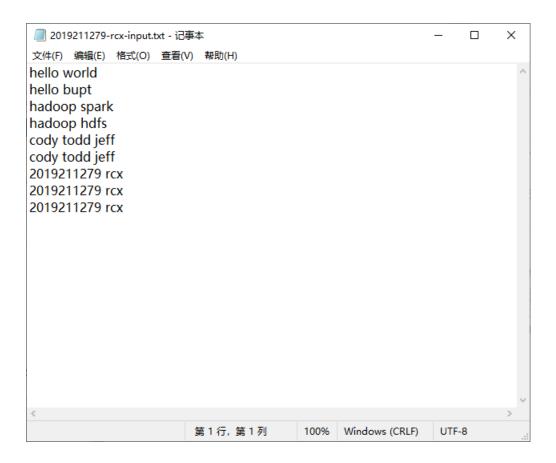


步骤 6: 使用压缩软件打开生成的 jar 包 (可以去本地电脑里找):

步骤 7: 找到 META-INF 目录,并删除 MANIFEST.MF 文件

步骤 8: 使用 WinSCP 上传处理后的 jar 包到服务器:

步骤 9: 构建输入文件,可在自己电脑构建然后上传到服务器中。格式为学号-姓名简写-input.txt,可通过 cat 命令打印检查。



步骤 10: 使用"hadoop jar <jar 包名> <主函数> <其余参数>"命令,在 hadoop 运行程序:

得到如下图运行结果:

步骤 11: 在 hdfs 上查看程序的输出:

```
root@rcx-2019211279-0001:~
drwxr---- - root supergroup 0 2022-04-05 02:43 /tmp/hadoop-yarn/staging
drwxr-wr-x - root supergroup 0 2022-04-05 02:43 /tmp/hadoop-yarn/staging/history
drwxrwxrwt - root supergroup 0 2022-04-05 02:43 /tmp/hadoop-yarn/staging/history/done_intermediate
drwxrwx-- - root supergroup 0 2022-04-05 02:43 /tmp/hadoop-yarn/staging/history/done_intermediate/root
-rwxrwx--- 3 root supergroup 33701 2022-04-05 02:43 /tmp/hadoop-yarn/staging/history/done_intermediate/root/job_1
649094707753_0001-1649097805374-root-word+count-1649097834016-1-1-SUCCEEDED-root.root-1649097815909.jhist
-rwxrwx--- 3 root supergroup 347 2022-04-05 02:43 /tmp/hadoop-yarn/staging/history/done_intermediate/root/job_1
949094707753_0001-164909780537

-rwxrwx--- 3 root supergroup

549094707753_0001.summary

-rwxrwx--- 3 root supergroup

549094707753_0001_conf.xml
                                                                                                  0 2022-04-05 02:43 /tmp/hadoop-yarn/staging/root
0 2022-04-05 02:43 /tmp/hadoop-yarn/staging/root/.staging
0 2022-04-05 02:43 /tmp/logs
0 2022-04-05 02:43 /tmp/logs/root
0 2022-04-05 02:43 /tmp/logs/root
0 2022-04-05 02:43 /tmp/logs/root/logs
0 2022-04-05 02:44 /tmp/logs/root/logs/application_1649094707753_0001
8070 2022-04-05 02:44 /tmp/logs/root/logs/application_1649094707753_0001/rcx-201921
                              - root supergroup
- root supergroup
drwx-----
rw-r---- 3 root root
279-0003_42263
                                                                                                39831 2022-04-05 02:44 /tmp/logs/root/logs/application_1649094707753_0001/rcx-201921
 rw-r---- 3 root root
279-0004_38507
                                                                                                   5383 2022-04-05 02:44 /tmp/logs/root/logs/application_1649094707753_0001/rcx-201925
1279-0004_38507
-rw-r--r-- 3 root supergroup 107 2022-03-25 17:06 /upload_2019211279.txt

drwxr-xr-x - root supergroup 0 2022-04-05 02:03 /user

drwxr-xr-x - root supergroup 0 2022-04-05 02:03 /user/hdfs

drwxr-xr-x - root supergroup 0 2022-04-05 02:39 /wordcount

-rw-r-r-- 3 root supergroup 130 2022-04-05 02:39 /wordcount/

-rw-r-r-- 3 root supergroup 130 2022-04-05 02:39 /wordcount/2019211279-rcx-input.txt

[root@rcx-2019211279-0001 ] # hadoop fs -cat /output/rcx-2019211279-out.txt/part-r-0000

22/04/05 02:50:57 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform.. using builtin-ja
2019211279
cody
nadoop
ndfs
nello
jeff
  odd
root@rcx-2019211279-0001 ~]#
```

五、实验结果与分析

(1) 粘贴实验结果图 28

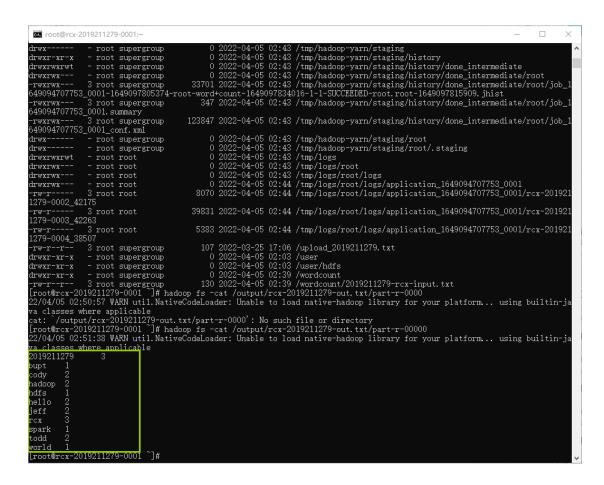
```
文件(P. 编辑(E.) 视图(M.) 导航(M.) 代码(C.) 重构(R.) 构建(B.) 运行(U.) 工具(T.) VCS(S.) 窗口(M.) 帮助(H.)
p2 [myWordCount] F:\B\idea\projects\p2
                                                               import org.apache.hadoop.conf.Configuration;
           myWordCount.jar
                                                               import org.apache.hadoop.mapreduce.Job;
   ✓ 🖿 src
    ∨ I main
                                                               import org.apache.hadoop.mapreduce.Reducer
                                                               import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
         > META-INF
           @ WordCount
     ∨ test
                                                               import java.io.IOException;
import java.util.StringTokenizer;
     > generated-sources
                                                               public class WordCount {
                                                                   public static class TokenizerMapper extends Mapper<Object, Tex
    private final static IntWritable one = new IntWritable( ve
> |||| 外部库
  6 临时文件和控制台
                                                                        private Text word = new Text();
                                                                             StringTokenizer itr = new StringTokenizer(value.toStri
```

(2) 粘贴实验结果图 33

(3) 粘贴实验结果图 34

```
| Description |
```

(4) 粘贴实验结果图 35



(5) 提交 jar 包

见压缩包

- (6) 解释 wordcount 程序代码,3 个类的作用,类之间的关系 见实验步骤中代码注释
- (7) 实验中应对各个截图进行简单解释,证明理解截图含义 见实验步骤